

Pourquoi configurer Kno selon votre usage ?

Les paramètres du moteur IA de Kno permettent d'optimiser finement le comportement de l'assistant selon la nature de vos documents. Ce catalogue présente 4 profils préconfigurés, une section performance matérielle, et un lexique détaillé de chaque paramètre.

Profils de configuration par usage

01

Analyse Juridique & Contrats

PDF et DOCX denses — clauses, jurisprudence, contentieux

Paramètre	Valeur	Impact & recommandation
Extraits recuperes (K)	5 – 7	Brasse large pour ne rater aucune clause liée. Ex : une clause de résiliation peut renvoyer à 3 articles distincts.
Taille des chunks	800 – 1000	Conserve des paragraphes entiers cohérents. Évite de couper une clause en milieu de phrase.
Overlap	200	Indispensable : une clause juridique coupée entre deux extraits peut inverser le sens d'une obligation.
Temperature	0.0 – 0.1	Strictement factuel. Aucune créativité tolérée sur des données contractuelles.

Attention contexte : $K=7 \times \text{chunk}=1000 \sim 7\,000$ tokens. Avec Mistral-7B (ctx 4096), privilégier $K=5$ si $\text{chunk} > 900$.

Formats cibles : PDF (contrats, actes), DOCX (procédures, modèles), TXT (jurisprudence exportée).

02

Données Tabulaires & Rapports Chiffres

XLSX, CSV et tableaux intégrés dans des PDF

Paramètre	Valeur	Impact & recommandation
Extraits recuperes (K)	8 – 10	Les données sont souvent réparties sur plusieurs lignes/colonnes : il faut brasser large pour reconstituer le contexte complet.
Taille des chunks	400	Tres court pour isoler précisément une ligne ou une cellule. Un chunk trop grand noie la valeur recherchée.
Overlap	50	Faible : les données tabulaires sont indépendantes d'une ligne à l'autre. Un overlap élevé créerait du bruit.
Temperature	0.0	Precision mathématique absolue. Aucune paraphrase acceptée sur des données chiffrées.

Note performance : $K=8-10$ est gourmand en calcul. GPU recommande (RTX 3060+) pour ce profil. En CPU pur, réduire à $K=6$.

Formats cibles : XLSX, CSV importe en TXT, PDF avec tableaux. Privilégier l'export CSV pour les données purement chiffrées.

03 Base de Connaissance RH & Onboarding

Procédures internes, livrets d'accueil, DOCX et MD

Parametre	Valeur	Impact & recommandation
Extraits recuperes (K)	3	Suffisant pour une reponse directe sur des documents bien structures. Evite les reponses trop longues.
Taille des chunks	600	Format standard equilibre pour une lecture fluide. Adapte aux paragraphes de procedures et fiches de poste.
Overlap	100	Valeur par defaut recommandee. Suffisant pour conserver le lien entre deux etapes d'une procedure.
Temperature	0.4 – 0.5	Rend le ton de l'assistant plus humain et accueillant pour les nouveaux collaborateurs.

Formats cibles : DOCX (procedures, fiches de poste), MD (wiki interne), TXT (notes onboarding).

Conseil : creer une collection "RH" dediee pour isoler ce corpus des documents juridiques ou techniques.

04 Documentation Technique & Wikis IT

Guides d'utilisation, runbooks, support IT

Parametre	Valeur	Impact & recommandation
Extraits recuperes (K)	4	Equilibre entre rapidite et couverture. Les docs techniques sont souvent bien structures et non redondants.
Taille des chunks	500	Cible une etape precise d'une procedure. Assez court pour isoler une commande ou un parametre specifique.
Overlap	150	Conserve le contexte de l'etape precedente/suivante. Crucial quand les etapes sont numerotees et dependantes.
Temperature	0.2	Equilibre entre precision technique et clarte d'explication.

Formats cibles : MD (wikis, README), TXT (logs, runbooks), PDF (manuels constructeurs).

Conseil : segmenter par produit ou systeme (ex : collection "Reseau", "Serveurs", "Applications").

Tableau de synthese rapide

Profil	K	Chunk	Overlap	Temperature	GPU ?
Juridique & Contrats	5 – 7	800 – 1000	200	0.0 – 0.1	Recommande
Tabulaire & Chiffres	8 – 10	400	50	0.0	Fortement recommande
RH & Onboarding	3	600	100	0.4 – 0.5	Optionnel
Tech & Wiki IT	4	500	150	0.2	Optionnel

Recommandations Performance & Materiel

Configuration	GPU	Temps estime	Profils compatibles
CPU seul (default)	Aucun	60 – 180 s	RH, Tech (K faible)

Configuration	GPU	Temps estime	Profils compatibles
CPU + GPU entree de gamme	RTX 3060 12 Go — layers 35	10 – 25 s	Tous profils
GPU mid-range	RTX 4070 12 Go — layers 40	5 – 10 s	Tous profils, K eleve
GPU haut de gamme	RTX 4080/4090 — layers 50+	2 – 5 s	Tous + Mixtral 8x7B
Apple Silicon (Mac)	M4 Pro / M5 Max	3 – 6 s	Tous — ideal cabinet

Parametrage GPU : regler `n_gpu_layers` dans Admin → Moteur LLM. Necessite llama-cpp compile avec CUDA (Windows) ou Metal (macOS).

Lexique des parametres Kno

Definitions detaillees a destination des administrateurs et referents techniques.

Retrieval	K — Extraits recuperes Nombre de fragments (chunks) recuperes dans l'index vectoriel avant de generer une reponse. Plus K est eleve, plus l'IA dispose d'informations mais plus la reponse est lente. <i>Exemple : K=3 lit les 3 passages les plus proches de la question. K=7 couvre plus de clauses liees dans un contrat dense.</i> Plage : 1 – 10 Default : 3
Indexation	Taille des chunks Lors de l'indexation, Kno decoupe chaque document en petits fragments appeles "chunks". Ce parametre definit la taille maximale de chaque fragment en nombre de caracteres. <i>Exemple : Chunk=400 isole une ligne de tableau. Chunk=1000 preserve le contexte d'un paragraphe juridique entier.</i> Plage : 200 – 2000 Default : 700
Indexation	Overlap (Chevauchement) Nombre de caracteres communs entre deux chunks consecutifs. Evite de perdre une information situee a la frontiere entre deux fragments. <i>Exemple : Overlap=200 repete les 200 derniers caracteres du chunk 1 au debut du chunk 2 — utile pour une clause a cheval entre deux pages.</i> Plage : 0 – 500 Default : 100
Generation LLM	Temperature Controle le "niveau de creativite" du modele IA. Valeur basse = reponses deterministiques et factuelles. Valeur haute = reponses plus variees et naturelles. <i>Exemple : 0.0 = reponse identique a chaque question identique (ideal chiffres). 0.5 = formulation variee (adapte RH).</i> Plage : 0.0 – 1.0 Default : 0.1
Performance	n_gpu_layers — Couches GPU Nombre de couches du modele LLM dechargees sur le GPU (CUDA/Metal). Chaque couche deplacee accelere significativement l'inference. <i>Exemple : 0 = CPU seul ~2-5 tok/s. layers=35 sur RTX 3060 ~20-40 tok/s. layers=50 sur RTX 4090 ~60-80 tok/s.</i>

Format fichier	GGUF — Format de modele Format de fichier standard pour les modeles de langage quantifies. Utilise par llama.cpp, le moteur IA embarque dans Kno. Fichiers autonomes sans dependances. <i>Exemple : Mistral-7B-Instruct-v0.3.Q4_K_M.gguf — modele 7B parametres, quantification 4 bits qualite medium, taille 4.4 Go.</i> Extension : .gguf Chemin : models/
Architecture	RAG — Retrieval-Augmented Generation Architecture combinant une recherche dans une base documentaire (retrieval) avec la generation de reponse par un LLM. Kno utilise FAISS pour la recherche et llama.cpp pour la generation. <i>Exemple : "Quel est le preavis dans le contrat Dupont ?" → (1) recherche K chunks proches, (2) envoie au LLM, (3) LLM cite la source [1].</i> N/A — principe architectural de Kno
Moteur recherche	Index vectoriel (FAISS) Base de donnees stockant les documents sous forme de vecteurs numeriques. La recherche semantique comprend le sens : "resilier un bail" et "rupture de contrat de location" donnent les memes resultats. <i>Exemple : Apres indexation de 90 PDF → ~6 000 vecteurs FAISS. Une question declenche une recherche parmi ces 6 000 vecteurs en millisecondes.</i> Chemin : vectorstore/ — 1 index par collection
Comportement LLM	Prompt systeme Instruction cachee envoyee au modele avant chaque question, definissant son role et ses contraintes. Dans Kno, impose de n'utiliser que les extraits fournis et de citer les sources. <i>Exemple : Modifier pour preciser "Tu es un assistant juridique specialise en droit des societes. En cas de doute, dis-le explicitement."</i> Champ texte libre — Admin > Moteur LLM
Organisation	Collection Espace de stockage isole avec ses propres documents, son propre index FAISS. Kno cherche uniquement dans la collection selectionnee lors d'une question. <i>Exemple : Collection "Contrats" (200 contrats clients) + Collection "RGPD" (politiques). Une question dans "Contrats" ne recherche jamais dans "RGPD".</i> Nombre illimite — Admin > Collections